부문(경제)

금융 뉴스와 거시 경제 변수를 활용한 XG boost 기반 코스피 시장 버블 예측

왕십리경제왕

초록

본 연구는 최근 코스피(KOSPI) 시장의 상승세가 기업 펀더멘털의 개선인지 자산가격 버블인지를 계량경제학적으로 검증하고, 그 발생 가능성을 예측할 수 있는지 분석한다. 거시경제·금융 변수 및 뉴스 기반 투자심리 지표를 입력으로 하는 머신러닝 분류 모형이 통계적 기준모형 대비 코스피 버블 구간을 유의미하게 예측할 수 있다는 가설을 설정하였다.

이를 검증하기 위해 2005 년부터 2025 년까지의 코스피 시계열 데이터를 바탕으로 3 단계 프레임워크를 적용했다. 먼저 GSADF 검정(PSY 절차)을 통해 통계적으로 유의한 다중 버블 구간을 식별하고, 탐지된 라벨을 바탕으로 불균형 분류 환경에 적합한 XGBoost 모형을 구축하여 out-of-sample 예측 성능을 평가하였다.

분석 결과, 총 10 개의 버블 에피소드가 탐지되었다. XGBoost 모형이 F1-macro 지표에서 로지스틱 회귀 및 단순 기준모형을 상회하였으며, PR-AUC 에서는 모든 모형이 기준 모형을 유의하게 상회하는 예측 성능을 보였다. 특히 시장 밸류에이션(PBR, PER), 통화량(M2), 뉴스 심리지수가 버블 예측에 핵심적인 역할을 수행함이 확인되었다. 본 연구는 미국 시장 중심의 선행연구를 넘어, 한국 주식시장의 구조적 특성을 반영한 버블 탐지 및 조기경보 체계 구축의 실증적 근거를 제시한다는 데 의의가 있다.

Keywords: 거시경제변수, 버블예측, 자산가격버블, 조기경보체계, 투자심리지수, GSADF, KOSPI, Machine Learning, PSY, XGBoost

1. 서론

최근 코스피(KOSPI)는 거시경제 불확실성에도 불구하고 구조적 상승 흐름을 지속하고 있다. 글로벌 유동성 환경 변화, 반도체 산업 회복 기대, 그리고 개인투자자의 적극적인 시장 참여 확대 등 다양한 요인이 복합적으로 작용하며 지수는 새로운 국면에 진입한 것으로 평가된다. 그러나 이러한 상승이 기업의 펀더멘털 개선에 기반한 합리적 가격 조정인지, 아니면 과도한 기대와 유동성에 의해 형성된 자산가격 버블인지에 대해서는 명확한 실증적 검증이 이루어지지 않았다. 본 연구는 바로 이러한 문제의식에서 출발한다. 즉, 현재 코스피의 상승이 통계적으로 식별 가능한 버블 국면에 해당하는지, 그리고 그 발생 가능성을 예측할 수 있는지에 대한 체계적 분석을 시도하고자 한다.

버블이 학문적·정책적으로 중요한 이유는 그 형성 자체보다도 붕괴 시 발생하는 경제적 파급효과에 있다. 역사적으로 자산가격 버블의 붕괴는 금융불안과 실물경제 침체로 이어지는 경우가 많았다. 닷컴 버블 붕괴, 2007-2008 년 글로벌 금융위기 등은 자산가격 급락이 신용경색, 금융기관 부실, 소비 및 투자 위축으로 확산될 수 있음을 보여준다. 특히 자산가격이 금융시스템의 담보가치 및 자산건전성과 밀접하게 연계되어 있는 경우, 버블 붕괴는 시스템 리스크로 전이될 가능성이 높다.

~~자산가격 버블은 금융시장에서 반복적으로 나타나는 현상이며, 실물경제에 중대한 충격을 초래할 수 있는 구조적 위험요인으로 인식되어 왔다. Shiller (2000)는 자산가격이 기업의 기초가치를 초과하여 지속적으로 상승하는 현상을 "비이성적 과열"로 설명하며, 투자자 심리의 중요성을 강조하였다. 이후 Phillips, Shi, Yu (2015)가 제안한 SADF 및 GSADF 검정은 자산가격 시계열의 폭발적 특성을 통계적으로 탐지함으로써 다중 버블 구간을 식별할 수 있는 방법론을 제시하였다. 최근에는 이러한 계량경제학적 접근을 넘어, 거시경제 변수와 뉴스 기반 감성 지표를 결합한 머신러닝 모형을 통해 버블 발생 확률을 사전에 예측하려는 연구도 확대되고 있다.~~

메모 포함[상박1]: 문단 전체가 뒤와 중복된 내용이라 삭제

그러나 기존 연구의 상당수는 미국 시장, 특히 S&P 500 을 중심으로 수행되어 왔으며, 한국과 같은 개방도가 높은 중견 시장에 대한 실증 연구는 상대적으로 제한적이다. 코스피는 몇 가지 독특한 구조적 특성을 지닌다. 첫째, 시가총액 상위 종목의 집중도가 높아 특정 산업, 특히 반도체 산업의 기대 변화가 지수 전체에 큰 영향을 미친다. 둘째, 외국인 투자자 비중이 높아 글로벌 금리, 환율, 해외 증시 흐름 등 대외 변수에 민감하게 반응하는 개방형 시장 구조를 갖는다. 셋째, 최근 개인투자자의 시장 참여 비중이 크게 확대되면서 수급 구조와 가격 형성 과정에 변화가 나타나고 있다. 개인투자자의 증가는 시장 유동성을 확대하는 동시에 투자자 구성의 변화를 초래하며, 이는 가격 변동성과 기대 형성 방식에 영향을 미칠 가능성이 있다. 이러한 구조적 변화는 한국 시장에서의 버블 형성 과정이 미국 시장과는 다소 상이하게 나타날 수 있음을 시사한다.

이에 따라 본 연구는 계량경제학적 버블 탐지 기법과 머신러닝 기반 예측 모형을 결합한 통합적 접근을 통해, 한국 주식시장에서의 버블 형성과 붕괴 과정을 체계적으로 분석하고자 한다. 이를 통해 미국 중심의 기존 연구 결과가 한국 시장에서도 재현되는지 여부를 검증함과 동시에, 정책당국과 시장 참여자에게 실질적인 조기경보 체계 구축의 가능성을 제시하는 데 기여하고자 한다.

2. 선행연구

2.1 버블의 정의와 중요성

자산가격 버블은 금융경제학에서 오랜 기간 논의되어 온 핵심 주제 중 하나이다. 전통적인 자산가격 모형에 따르면, 주식 가격은 미래 배당의 기대현재가치로 설명된다. 이러한 관점에서 버블은 자산가격이 기초가치로 설명되는 경로를 지속적으로 초과하여 형성되는 현상으로 정의된다. 즉, 가격이 단순히 상승하는 것이 아니라, 이론적으로 정당화되는 가치 수준에서 구조적으로 이탈하는 상태를 의미한다(West, 1987; Diba & Grossman, 1988).

버블의 존재 가능성에 대해서는 합리적 기대 하에서도 설명이 가능하다는 이론적 논의가 존재한다. Blanchard and Watson (1982)은 합리적 버블 모형을 통해, 투자자들이 가격이 기초가치에서 이탈하고 있음을 인지하더라도 향후 더 높은 가격에 매도할 수 있다는 기대가 유지되는 한 버블이 지속될 수 있음을 보였다. 이와 같은 합리적 버블 모형은 버블을 단순한 비이성적 과열이 아니라, 기대 형성과 시장 구조에 의해 유지될 수 있는 균형 경로로 해석한다는 점에서 중요한 이론적 기반을 제공한다.

~~버블이 학문적·정책적으로 중요한 이유는 그 형성 자체보다도 붕괴 시 발생하는 경제적 파급효과에 있다. 역사적으로 자산가격 버블의 붕괴는 금융불안과 실물경제 침체로 이어지는 경우가 많았다. 닷컴 버블 붕괴, 2007-2008년 글로벌 금융위기 등은 자산가격 급락이 신용경색, 금융기관 부실, 소비 및 투자 위축으로 확산될 수 있음을 보여준다. 특히 자산가격이 금융시스템의 담보가치 및 자산건전성과 밀접하게 연계되어 있는 경우, 버블 붕괴는 시스템 리스크로 전이될 가능성이 높다.~~

메모 포함[상박2]: 앞부분으로 옮김

2.2 계량적 버블 탐지 방법의 발전

계량경제학 문헌에서는 버블을 가격 시계열의 통계적 특성을 통해 식별하려는 접근이 발전해왔다. 초기에는 Augmented Dickey-Fuller(ADF) 검정을 통해 단위근 존재 여부를 판단하였으나(Dickey & Fuller, 1979), 이는 시계열의 비정상성 여부만을 검정할 뿐, 특정 구간에서의 폭발적 움직임을 구분하는 데에는 한계가 있다.

이를 보완하기 위해 Phillips, Wu, and Yu (2011)는 우측 꼬리 단위근 검정을 제안하였다. SADF(Supremum ADF) 검정은 재귀적 방식으로 검정을 수행하여 가격 시계열 내 폭발적 구간을 탐지할 수 있도록 설계되었다. 이후 Phillips, Shi, and Yu (2015)는 시작점과 종료점을 모두 이동시키는 GSADF(Generalized Supremum ADF) 검정을 제시하여, 장기간 자료에서 다중 버블을 식별할 수 있는 방법을 확립하였다. 이러한 GSADF 기반 절차는 흔히 PSY 방법으로 불리며, 버블의 형성과 붕괴 시점을 날짜 수준으로 특정하는 데이트스탬핑(date-

stamping)을 가능하게 한다. 이러한 접근은 버블을 기초가치 추정에 의존하지 않고, 가격 경로 자체의 통계적 특성을 통해 식별할 수 있다는 점에서 실증 연구에서 널리 활용되고 있다.

예를 들어, Ozgur, Yilanci, and Ozbugday (2021)는 금속가격의 투기적 버블을 탐지하기 위해 GSADF 검정을 활용하였으며, Shu and Song (2024)은 LPPLS 모형과 함께 GSADF 계열 검정을 비교 분석하였다. 또한 Phillips and Shi (2020)는 자산시장 실시간 모니터링에 관한 서술적 논의에서 GSADF 기반 접근을 핵심 도구로 정리하였다. 이러한 흐름은 GSADF/PSY 절차가 단일 사례 연구에 그치지 않고, 반복적 실증 적용을 통해 확산되어 왔음을 보여준다.

2.3 머신러닝 기반 버블 예측

버블 탐지 방법이 발전함에 따라, 최근 연구는 버블을 사후적으로 식별하는 데 그치지 않고, 탐지된 버블 구간을 예측 대상으로 설정하는 방향으로 확장되고 있다. 전통적인 조기경보 연구는 주로 로지스틱 회귀나 프로빗 모형을 활용하여 금융위기 발생 가능성을 추정하는 데 초점을 맞추어 왔다(Alessi & Detken, 2011; Sarlin, 2013). 그러나 이러한 모형은 변수 간 비선형 관계나 고차 상호작용을 충분히 반영하기 어렵다는 한계를 가진다.

이에 따라 최근에는 머신러닝 기법을 활용하여 금융시장 위험을 예측하려는 연구가 증가하고 있다. Chatzis et al.(2018)은 다양한 머신러닝 알고리즘을 활용하여 금융위기 이벤트를 예측하였으며, 복잡한 비선형 패턴을 포착하는 데 있어 전통적 통계모형보다 우수한 성능을 보일 수 있음을 제시하였다. 이러한 흐름은 금융위기뿐 아니라 자산가격 버블 예측으로도 확장되고 있다.

특히 PSY/GSADF 절차를 통해 탐지된 버블 구간을 '정답(label)'으로 설정한 뒤, 거시경제 및 시장 변수들을 활용하여 버블 발생 여부를 분류하는 접근이 최근 등장하고 있다. Ozgur et al.(2021)은 GSADF 검정을 통해 금속시장 버블을 식별한 후 Random Forest 를 적용하여 예측 변수를 분석하였으며, Ba¸so˘glu Kabran and Ünlü (2021)는 S&P 500 을 대상으로 SVM 기반 분류모형을 구축하였다. Atsiwo (2025)는 PSY 기반 라벨을 활용한 3 단계 구조를 제시하고,

XGBoost, Random Forest, AdaBoost 등의 성능을 비교한 결과, 불균형 데이터 환경에서 XGBoost 가 상대적으로 우수한 분류 성능을 보였음을 보고하였다

2.4 한국 시장에서의 버블 탐지 및 예측

Phillips et al. (2015)의 우측 단위근 기반 버블 탐지 방법은 국내 자산시장에도 적용되어 왔다. 예컨대 국내 부동산 시장을 대상으로 GSADF 또는 반복적 우측 단위근 검정을 활용하여 버블의 형성과 붕괴 시점을 추정한 연구들이 보고되었으며, 지역별 아파트 시장의 과열 구간을 식별한 사례가 존재한다(KCI 등재 학술지). 또한 상업용 부동산 시장을 대상으로 RADF/GSADF 절차를 적용하여 버블 구간을 분석한 연구 역시 확인된다(KCI 등재).

주식시장에 대해서도 관련 연구가 이루어졌다. 양혜진·이진 (2024)은 코스피 및 코스닥 산업별 주가를 대상으로 후행 반복적 ADF 검정을 적용하여 버블 발생 및 소멸 시점을 식별하고, 벌칙화된 로짓 모형을 통해 예측 변인을 선별하였다. 이는 국내 주식시장 자료에 PSY 계열 검정을 적용하고, 탐지 결과를 예측 분석으로 확장한 사례로 볼 수 있다.

이처럼 국내 문헌에서는 (1) GSADF/PSY 기반 버블 탐지의 적용과 (2) 통계적 모형을 활용한 예측 분석이 각각 수행되어 왔다. 다만 코스피 지수 수준에서 PSY 기반 탐지 결과를 예측 대상 변수로 설정하고, 이를 비선형 머신러닝 분류 모형과 결합하여 버블 발생 확률을 체계적으로 산출하는 분석 구조는 국내 연구에서 명시적으로 제시된 사례가 제한적으로 확인된다.

이에 본 연구는 국제적으로 확립된 PSY 기반 버블 탐지 절차를 코스피 지수에 적용하고, 탐지된 버블 구간을 예측 대상으로 설정하여 머신러닝 모형을 통해 발생 확률을 추정함으로써, 탐지와 예측을 통합한 실증적 분석 프레임워크를 제시하고자 한다.

3. 연구설계 및 방법(Methods)

3.1 가설 설정

본 연구의 목적은 PSY 절차를 통해 정의된 코스피 버블 구간이 거시·금융 변수를 활용한 머신러닝 모형을 통해 예측 가능한지를 실증적으로 검증하는 데 있다. 이에 따라 다음과 같은 연구가설을 설정한다.

H0

XGBoost 모형의 예측 성능은 기준모형과 유의미한 차이가 없다.

H1

PSY 절차로 정의된 코스피 버블 라벨은 거시·금융 변수를 입력으로 하는 XGBoost 분류모형을 통해 기준모형 대비 유의미하게 예측 가능하다.

여기서 기준모형은 (i) 항상 비버블 상태를 예측하는 단순 모형과 (ii) 전통적 통계모형인 로지스틱 회귀를 포함하며, 예측 성능은 불균형 분류 상황을 고려하여 PR-AUC, F1-macro 및 balanced accuracy 지표를 통해 비교한다. 본 연구는 시계열 분할을 활용한 out-of-sample 검증을 통해 모형의 일반화 가능성을 평가한다.

3.2 모델 설계

본 연구는 버블 탐지와 예측을 통합하기 위해 3단계 구조(Three-Step Framework)를 채택하였다. 이는 (1) 버블 탐지, (2) 데이터셋 구성, (3) 머신러닝 예측으로 구성된다.

3.2.1 Step 1: PSY 기반 버블 탐지

버블 탐지는 Phillips et al. (2015)가 제안한 GSADF(Generalized Supremum Augmented Dickey-Fuller) 검정을 활용하였다. GSADF는 시작점과 종료점을 재귀적으로 이동시키며 우측 단위근 검정을 수행함으로써 시계열 내 다중 버블 구간

을 식별할 수 있도록 설계된 방법이다.

본 연구에서는 코스피 지수의 로그 가격을 활용하여 폭발적 경로의 존재 여부를 검정하였다. 최소 윈도우 길이(r_0)는 표본 길이 T=252를 고려하여 15개월($r_0 = \frac{15}{T} \approx 0.060$)로 설정하였다. ~~PSY(2015)의 권장 공식~~ R패키지 문서에서 확인되는 PSY 구현 표준 공식 $r_0 = 0.01 + \frac{1.8}{\sqrt{T}}$를 적용할 경우 약 31개월이 되어, 단기 버블 에피소드가 장기 윈도우 평균에 희석되어 검출되지 않는 문제가 발생하였다. ~~이에 따라 선행연구(Atsiwo, 2025)에서 소규모 표본에 대해 윈도우를 축소 조정한 사례를 참고하여, 15개월로 설정함으로써 검정력과 안정성 간 균형을 확보하였다.~~ 이에 ADF 회귀의 안정적 추정에 필요한 최소 관측치 수준인 15개월로 축소 설정하였다. 단, 이러한 파라미터 선택이 결과에 미치는 영향은 4.2.1절 민감도 분석에서 검증한다. 임계값은 Monte Carlo 시뮬레이션(500회)을 통해 산출하였다. 각 시뮬레이션에서 표본 길이 T의 랜덤워크를 생성한 후 GSADF 통계량을 계산하여, 그 경험적 분포의 90% 분위수를 임계값으로 설정하였다.

버블 구간의 식별은 2단계로 수행하였다. 먼저 GSADF 통계량이 95% 임계값을 초과하는지 여부를 통해 분석 기간 전체에서 폭발적 가격 경로의 존재 여부를 검정하였다. 이후 BSADF(Backward SADF) 통계량을 활용하여 개별 시점의 버블 여부를 판별하는 데이트스탬핑 절차를 적용하였다. BSADF는 종료점을 t로 고정한 상태에서 시작점을 최소 표본 구간부터 t까지 재귀적으로 확장하며 수행한 ADF 검정 통계량 중 최대값으로 정의된다. ~~각 시점에서 BSADF$_t$가 대응 임계값을 초과하는 경우 해당 시점을 버블 구간으로 분류하였다.~~ 이러한 데이트스탬핑 절차를 통해 버블의 시작 및 종료 시점을 식별하였다. ~~본 방법은 기초가치 추정에 의존하지 않고 가격 경로의 통계적 폭발성에 기반하여 버블을 정의한다는 점에서 이론적 정합성을 가진다.~~

메모 포함[상박3]: 출처 불분명으로 R 패키지 문서를 출처로 변경

메모 포함[상박4]: 선행연구에 그런 내용 없음;; 그래서 뒷문장 추가

메모 포함[상박5]: 클로드 추천으로 삭제(대응이라는 표현을 쓰면 시점별로 다른 임계값을 적용하는 것처럼 보인다고 함)

메모 포함[상박6]: 필요 없어보여서 삭제

수식 1 ADF 회귀식

$$\Delta yt = \alpha + \beta yt - 1 + \varepsilon t$$

여기서,

$y_t = \log(\text{KOSPI})$

귀무가설: $H_0: \beta = 0$(단위근 존재)

대립가설: $H_1: \beta > 0$(폭발적 행태)이다.

메모 포함[상박7]: 추가

수식 2 BSADF 및 GSADF 정의

$$BSADF_t = \sup_{r_1 \in [0, t-r_0]} ADF_{r_1}^t$$

$$GSADF = \sup_{t \in [r_0, 1]} BSADF_t$$

여기서,

r_0: 최소 윈도우 비율

$ADF_{r_1}^t$: 구간 $[r_1, t]$에서 추정된 ADF 통계량이다.

메모 포함[상박8]: 추가

3.2.2 Step 2: Dataset Construction

탐지된 버블 구간을 예측 대상으로 설정하기 위해 시계열 자료를 재구성하였다. 본 연구의 분류 문제는 시점 t에서 관측 가능한 거시·금융 변수를 활용하여 동일 시점 t의 버블 상태를 식별하는 동시적 구조로 설계하였다. 이는 PSY 검정이 가격 경로의 통계적 특성에 기반하여 사후적으로 정의한 버블 라벨을, 동일 시점의 거시경제 환경이 설명할 수 있는지를 검정하는데 목적이 있다. ~~월별 거시·금융 변수는 해당 월 종료 시점에 확정되므로, 본 구조는 월말 시점에서 당월의 버블 상태를 판별하는 준실시간 식별 체계로 해석할 수 있으며, 이는 실무적으로 조기경보의 기초 단계에 해당한다.~~

메모 포함[상박9]: 빠져도 될 것 같아서 삭제

데이터는 월별 자료를 기준으로 2005년 1월부터 2025년 12월까지 구축하였다. 모든 변수는 시계열 정렬을 수행하였으며, 로그 변환 및 성장률 변환을 적용하였다.

메모 포함[상박10]: 데이터에 나와야 할 내용인 것 같아서 삭제

버블 발생은 전체 표본 중 상대적으로 적은 비중을 차지하므로, 본 연구는 불균형 분류 환경을 고려하여 평가 지표를 선택하였다.

수식 3 데이트 스탬핑 규칙

$$Bubble_t = \begin{cases} 1, if\ BSADF_t > cv_t^{90\%} \\ 0, otherwise \end{cases}$$

단, 전체 기간에 대해

$$\mathrm{GSADF} > \mathrm{cv}^{95\%}$$

가 선행적으로 충족된 경우에만 데이트스탬핑을 수행한다.

메모 포함[상박11]: 추가

3.2.3 Step 3: Machine Learning Prediction

버블 예측 모형으로는 XGBoost를 사용하였다. 또한 하이퍼파라미터 최적화는 시계열 구조를 유지하기 위하여 TimeSeriesSplit(3-fold) 기반 RandomizedSearchCV를 적용하였다. 탐색 대상 파라미터는 트리 깊이(max_depth: 2, 3, 4), 학습률(learning_rate: 0.05, 0.1), 트리 수(n_estimators: 100, 200, 300), 그리고 클래스 불균형을 보정하기 위한 scale_pos_weight를 포함하며, 총 12회의 무작위 탐색을 수행하였다. 평가 지표는 F1-macro를 사용하였다. 모형의 최종 성능은 학습 구간(2005.01~2019.08, 176개월)에서 학습한 후, 평가 구간(2019.09~2025.12, 76개월)에서의 out-of-sample 예측 결과를 기준으로 평가하였다.

수식 4: 분류 문제 정의

$$f: X_t \rightarrow Y_t, \qquad Y_t = (bubble_t, bubble_up_t, bubble_down_t)$$

시점 t의 설명변수 벡터

$$X_t \in \mathbb{R}^{11}$$

을 이용하여 동일 시점 t의 버블 상태 Y_t를 식별한다.

메모 포함[상박12]: 추가

과적합 방지 제약으로는 다음을 적용하였다.

- 트리 깊이 제한(max_depth)
- 학습률 감소(learning_rate)

클래스 불균형 보정으로는 다음을 적용하였다.

- scale_pos_weight

메모 포함[상박13]: 이거는 과적합 방지 제약이 아니라 해서 분류 추가

모형 성능은 다음 지표를 통해 평가하였다.

- PR-AUC
- F1-macro
- Balanced Accuracy

이와 함께 로지스틱 회귀모형과의 성능 비교를 수행하여 머신러닝 접근의 추가적 설명력을 검증하였다.

3.3 데이터 및 변수

3.3.1 데이터 구성 및 선정 배경

본 연구는 코스피(KOSPI) 시장의 버블 발생 가능성을 예측하기 위하여 시장 밸류에이션 변수, 거시경제 및 유동성 변수, 그리고 투자자 수급 변수를 포함한 시계열 데이터를 사용하였다. 주식시장 버블은 기업의 기초가치 변화만으로 설명되지 않는 가격 상승 현상으로, 기업의 실질 가치 대비 가격의 과도한 상승, 시장 내 유동성 증가, 그리고 투자자 자금 유입과 같은 요인들이 복합적으로 작용하여 형성되는 것으로 알려져 있다.

특히, 자산가격이 기업의 이익이나 자산과 같은 펀더멘털 대비 지속적으로 높은 수준을 유지하는 현상은 시장의 과대평가 상태를 의미하며, 이는 버블 형성의 주요 특징으로 간주된다 (Shiller, 2000). 또한 중앙은행의 통화정책 완화로 인해 시장 내 유동성이 증가할 경우 투자자들은 상대적으로 높은 수익률을 기대할 수 있는 주식시장으로 자금을 이동시키게 되며, 이는 자산가격 상승 압력으로 작용할 수 있다 (Bernanke & Gertler, 2001). 더불어 주식시장에서 실제로 발생하는 투자자 자금 흐름은 시장 가격 형성에 직접적인 영향을 미치며, 특히 외국인 및 기관 투자자의 순매수 증가는 시장 상승의 중요한 요인으로 작용할 수 있다 (Baker & Wurgler, 2006).

또한 선행연구에서는 거시경제 변수, 특히 GDP 성장률, 물가 수준, 금리와 같은 변수들이 자산가격 버블 예측에 중요한 역할을 하는 것으로 나타났다. 경제성장률은 기업 실적 개선 기대와 투자 심리를 반영하며, 물가 및 금리는 시장 내 유동성과 투자 환경을 나타내는 중요한 지표로 작용한다. 이러한 변수들은 자산가격 상승의 거시경제적 배경을 설명하는 핵심 요인으로 활용될 수 있다.

따라서 본 연구는 코스피 시장의 버블 형성과 관련된 주요 요인을 종합적으로 반영하기 위해 시장 밸류에이션 변수, 거시경제 및 유동성 변수, 그리고 투자자 수급 변수를 포함하였다.

분석 기간은 2005년 1월부터 2025년 12월까지로 설정하였다. 해당 기간은 글로벌 금융위기(2008년), 유럽 재정위기(2011년), 그리고 COVID-19 이후 유동성 확대 시기(2020년 이후) 등 다양한 시장 국면을 포함하고 있어, 시장 과열 및 버블 형성과 붕괴가 반복적으로 나타난 시기를 모두 포함한다는 점에서 버블 예측 모델을 구축하기에 적합하다.

데이터는 ~~국내 금융시장 및 거시경제 데이터를 체계적으로 제공하는~~ KRX 정보시스템, FnGuide DataGuide 및 한국은행 경제통계시스템(ECOS)을 통해 수집하였다.

메모 포함[상박14]: KRX에서도 받지 않았나..? 확인 필요

3.3.2 시장 밸류에이션 변수

시장 밸류에이션 변수는 주식시장의 가격 수준이 기업의 기초가치 대비 어느 정도 수준에 있는지를 측정하기 위한 변수이다. 주식시장 버블은 기업의 실제 수익이나 자산 가치의 증가 속도보다 주가 상승 속도가 더 빠르게 나타나는 현상으로 정의되며, 이러한 현상은 밸류에이션 지표의 상승을 통해 확인할 수 있다(Shiller, 2000).

PER (Price-to-Earnings Ratio)는 기업의 순이익 대비 주가 수준을 나타내는 지표로, PER가 상승할 경우 투자자들이 기업의 현재 수익 대비 더 높은 가격을 지불하고 있음을 의미한다. 이는 기업의 펀더멘털 대비 주가가 과도하게 상승했을 가능성을 나타내며, 시장 과열 상태를 반영하는 중요한 지표이다.

PBR (Price-to-Book Ratio)은 기업의 순자산 대비 시장가격 수준을 나타내는 지

표로, PBR이 높은 수준을 유지하는 경우 이는 기업의 자산 가치 대비 시장가격이 높게 형성되어 있음을 의미하며, 시장의 과대평가 가능성을 시사한다.

또한 KOSPI Return (코스피 수익률)은 시장 전체의 가격 상승 및 하락 추세를 나타내는 변수로, 지속적인 높은 수익률은 시장 내 투자 수요 증가 및 가격 상승 압력이 존재함을 의미한다. 특히 버블 형성 과정에서는 일정 기간 동안 가격 상승이 지속되는 특징이 나타나므로, 시장 수익률은 버블 형성과 관련된 중요한 설명 변수로 활용될 수 있다.

따라서 본 연구에서는 시장 밸류에이션 수준과 가격 상승 추세를 반영하기 위해 다음 변수를 사용하였다.

사용 변수:

- KOSPI Return
- PER
- PBR

3.3.3 거시경제 및 유동성 변수

거시경제 및 유동성 변수는 통화정책, 시장 내 유동성, 그리고 경제 전반의 거시적 환경이 자산가격에 미치는 영향을 반영하기 위한 변수이다. 일반적으로 유동성이 증가하고 경제 성장 기대가 높아질 경우, 투자자들은 주식시장에 더 많은 자금을 투자하게 되며 이는 자산가격 상승으로 이어질 수 있다.

Base Rate (기준금리)는 중앙은행의 통화정책 방향을 나타내는 대표적인 변수로, 금리가 낮아질 경우 예금 및 채권과 같은 안전자산의 기대수익률이 감소하게 된다. 이에 따라 투자자들은 상대적으로 높은 수익률을 기대할 수 있는 주식시장으로 자금을 이동시키게 되며, 이는 주식 수요 증가와 가격 상승으로 이어질 수 있다.

M2 (통화량)는 시중에 공급된 총 통화량을 나타내는 변수로, 시장 내 유동성 수준을 직접적으로 반영한다. 통화량 증가는 투자 가능한 자금 증가를 의미하며, 이는 금융시장으로의 자금 유입 증가 및 자산가격 상승으로 이어질 수 있다. 본

연구에서는 월별 평균잔액 기준의 계절조정계열을 사용하여 단기적 변동성을 완화하고 중·장기적 유동성 추세를 반영하였다.

GDP growth rate (국내총생산 성장률)는 경제 성장 수준을 나타내는 대표적인 변수로, 경제 성장률이 높을 경우 기업 실적 개선 기대와 함께 투자 심리가 개선될 수 있다. 이는 주식시장으로의 자금 유입 증가와 자산가격 상승으로 이어질 가능성이 있으며, 시장 과열 및 버블 형성과 관련될 수 있다. 국내총생산(GDP)은 분기 단위로 제공되므로, 월 단위 분석을 위해 각 분기 값을 해당 분기에 속하는 3개 월에 동일하게 적용하였다.

CPI (소비자물가지수)는 경제 내 물가 수준을 나타내는 변수로, 인플레이션 환경은 투자자의 자산 선택에 영향을 미칠 수 있다. 물가 상승은 실물자산 및 금융자산 투자 수요 증가로 이어질 수 있으며, 이는 자산가격 상승과 관련될 수 있다.

Long-term interest rate (장기금리)는 장기적인 경제 전망과 금융시장 환경을 반영하는 변수로, 장기금리 변화는 자산의 할인율 및 기대수익률에 영향을 미쳐 주식시장 가격 형성에 중요한 역할을 한다.

따라서 본 연구에서는 시장 내 유동성 및 거시경제 환경을 반영하기 위해 다음 변수를 사용하였다.

사용 변수:

- Base Rate
- M2
- GDP growth rate
- CPI
- Long-term interest rate

3.3.4 투자자 수급 변수

투자자 수급 변수는 주식시장 내 실제 자금 흐름을 반영하는 변수로, 시장 가

격 변동을 설명하는 중요한 요인이다. 주식시장 가격은 기업의 기초가치뿐만 아니라 투자자의 매수 및 매도 활동에 의해 결정되며, 특히 대규모 자금을 운용하는 투자자의 거래는 시장 가격에 직접적인 영향을 미칠 수 있다 (Baker & Wurgler, 2006).

Foreign Net Buy (외국인 순매수)는 외국인 투자자의 순자금 유입을 나타내는 변수로, 외국인 자금 유입 증가는 주식 수요 증가로 이어져 시장 상승 압력으로 작용할 수 있다.

Institutional Net Buy (기관 순매수)는 기관 투자자의 순매수 규모를 나타내며, 기관 투자자는 시장 내 주요 참여자로서 자산가격 형성에 중요한 영향을 미칠 수 있다.

이와 같이 외국인 및 기관 투자자 계정을 각각 구분하여 반영함으로써, 시장 내 투자자 자금 흐름이 자산가격 형성 및 버블 발생에 미치는 영향을 보다 구체적으로 분석할 수 있다.

따라서 본 연구에서는 투자자 자금 흐름을 반영하기 위해 다음 변수를 사용하였다.

사용 변수:

- Foreign Net Buy
- Institutional Net Buy

3.3.5 투자심리 지표 (Investor Sentiment Index)

본 연구는 시장 내 비이성적 기대와 심리적 과열이 자산가격 버블 형성에 미치는 영향을 반영하기 위하여 뉴스 기반 투자심리 지표를 추가적으로 포함하였다. 자산가격 버블은 펀더멘털 요인뿐 아니라 투자자의 낙관적 기대와 군집행동에 의해 확대되는 경향이 있으며, 이러한 심리적 요인은 전통적인 거시경제 변수만으로는 충분히 설명되기 어렵다 (Shiller, 2000; Baker & Wurgler, 2006).

본 연구에서 사용한 심리지표는 인터넷 포털사이트의 경제 분야 뉴스 기사 문

장을 대상으로 기계학습 기반 감성분석을 수행하여, 각 문장을 긍정, 부정, 중립으로 분류한 후, 일정 기간 동안의 긍정 문장 수에서 부정 문장 수를 차감하여 산출한 지수이다. 즉, 해당 지표는 시장 관련 뉴스에 내재된 낙관적 또는 비관적 정서를 정량화한 값으로, 값이 클수록 시장 전반에 낙관적 심리가 우세함을 의미한다.

선행연구에서는 투자심리가 개별 주식의 초과수익률이나 단기 가격 왜곡과 유의한 관련을 보인다는 결과가 보고된 바 있다(Baker & Wurgler, 2006). 그러나 기존 연구에서는 심리지표가 거시적 자산가격 버블을 직접적으로 설명하는 데에는 일관된 결과를 보이지 않았다. 이에 본 연구는 뉴스 기반 심리지표가 코스피 시장의 버블 형성과정에서 기존 거시경제 변수와는 다른 방식으로 작용할 가능성을 검증하고자 하였다. 특히 한국 주식시장은 개인 투자자 비중이 상대적으로 높고 정보 확산 속도가 빠른 시장 구조를 가지므로, 뉴스 감성이 시장 과열 국면에서 가격 상승 압력을 증폭시키는 요인으로 작용할 수 있다.

따라서 본 연구에서는 펀더멘털 및 거시 변수로 설명되지 않는 투자자의 심리적 요인을 반영하기 위하여 해당 감성 기반 투자심리 지표를 설명 변수에 포함하였다.

사용 변수:

- Investor Sentiment Index

3.3.6 PSY 검정 입력 변수: log(KOSPI)

본 연구에서는 PSY 검정의 입력 변수로 코스피 지수의 로그 가격(log price)을 사용하였다. 코스피 지수의 원시 수준값은 직접 이용할 수 없어, 월간 수익률로부터 다음과 같이 가격 지수를 재구성하였다.

$$KOSPI_t = 100 \times \prod_{k=1}^{t}\left(1 + \frac{Return_k}{100}\right)$$

이후 로그 변환을 적용하여 $y_t = \log(KOSPI_t)$를 PSY 검정의 입력 시계열로 사용하였다. 재구성된 log(KOSPI)의 범위는 약 4.62~6.15로, 분석 기간 동안 약 1.5의 변동폭을 보였다.

log(KOSPI)를 PSY 검정 변수로 채택한 근거는 다음과 같다. 첫째, Phillips, Shi, and Yu(2015)의 PSY 절차는 원래 자산가격의 로그 수준에서의 폭발적 행태를 탐지하도록 설계되었으며, 로그 가격은 Monte Carlo 시뮬레이션에서 생성되는 랜덤워크(cumulative sum of N(0,1))와 동일한 스케일 속성을 가진다. 둘째, 로그 변환은 가격의 수준 효과를 제거하고 수익률의 누적 구조를 반영하므로, 장기 시계열에서의 추세와 폭발적 이탈을 효과적으로 구분할 수 있다. 셋째, 실증 분석에서 $\log(KOSPI)$를 사용한 GSADF 통계량(2.93)은 95% 임계값(2.63)을 초과하여, P/D ratio를 사용한 경우(GSADF = 1.41 < CV_{95} = 2.28)와 달리 버블의 통계적 유의성을 확보할 수 있었다.

한편, 코스피 수익률(Return)은 PSY 검정 변수 산출을 위한 중간 입력으로 사용되었으나, 머신러닝 모형의 설명변수로도 동시에 포함되어 있다. 이는 정보 누수에 해당하지 않는데, PSY 검정에서는 수익률의 누적합인 로그 가격의 장기적 경로 특성을 분석하는 반면, 분류 모형에서는 개별 시점의 단월(single-month) 수익률을 독립적인 설명변수로 사용하기 때문이다. 즉, 동일한 원시 자료로부터 도출되지만 서로 다른 변환을 거쳐 상이한 정보를 반영하므로, 양자의 동시 사용은 방법론적으로 타당하다.

3.3.7 최종 사용 변수

본 연구에서는 코스피 시장의 버블 발생 가능성을 예측하기 위해 다음과 같은 변수를 최종 입력 변수로 사용하였다.

- Return
- PER
- PBR
- Base Rate

- M2
- GDP growth rate
- CPI
- Long-term interest rate
- Foreign Net Buy
- Institutional Net Buy
- Investor Sentiment Index

이러한 변수들은 각각 시장 밸류에이션 수준, 거시경제 및 유동성 환경, 그리고 투자자 자금 흐름을 반영하며, 자산가격 버블 형성과 관련된 주요 요인을 종합적으로 설명할 수 있는 변수 구성이다.

표1. 변수 정의 및 분류표

구분 (Category)	변수명 (Variable)	정의 (Definition)	단위 (Unit)	자료 출처 (Source)	빈도 (Frequency)
Valuation	Return	코스피 지수의 월간 수익률	%	ECOS	월별
Valuation	PER	코스피 주가수익비율	배	ECOS	월별
Valuation	PBR	코스피 주가순자산비율	배	ECOS	월별
Macro & Liquidity	BaseRate	한국은행 기준금리	%	ECOS	월별
Macro & Liquidity	M2	광의통화(M2, 계절조정계열)	십억원	ECOS	월별
Macro & Liquidity	GDP growth rate	실질 GDP 성장률	%	ECOS	분기 → 월 변환
Macro & Liquidity	CPI	소비자물가지수	지수	ECOS	월별
Macro & Liquidity	Long-term interest rate	국고채 10년물 수익률	%	ECOS	월별
Investor Flow	Foreign Net Buy	외국인 순매수 금액	십억원	ECOS	월별

Investor Flow	Institutional Net Buy	기관 순매수 금액	십억원	ECOS	월별
Sentiment	News Sentiment Index	표준화 심리 지수	지수	ECOS	월별

표 2. 기초통계량 (Descriptive Statistics)

	N	Mean	Std	Min	Max	Skewness	Kurtosis
Return	252	0.76	5.43	-23.13	19.94	-0.21	1.93
PER	252	14.84	4.45	7.37	32.6	1.58	3.4
PBR	252	1.16	0.22	0.71	1.9	0.68	0.42
BaseRate	252	2.51	1.2	0.5	5.25	0.36	-0.58
M2	252	2225007.38	966789.43	902992.8	4080672.2	0.45	-1.06
GDP G.R	252	0.77	0.89	-3.4	3.1	-1.7	6.97
CPI	252	94.7	11.76	73.59	117.57	0.06	-0.69
Long-term interest rate	252	3.44	1.31	1.25	6.03	0.23	-1.15
Foreign Net Buy	252	-157.85	3279.94	-14456.16	7858.31	-0.6	1.82
Institutional Net buy	252	23.53	2550.4	-17382.6	7860.54	-1.34	8.13
Sentiment	252	100	10	58.0	119.92	-0.93	1.83

표 3. 상관계수 행렬 (Correlation Matrix)

	Return	PER	PBR	BaseRate	M2	GDP G.R	CPI	Long-term interest rate	Foreign Net Buy	Institutional Net buy	Sentiment
Return	1	0.21	0.18	-0.05	0.01	0.17	-0.02	-0.01	0.53	-0.15	0.42
PER	0.21	1	0.05	-0.36	0.23	0.22	0.2	-0.21	0.04	-0.38	0.48
PBR	0.18	0.05	1	0.5	-0.65	0.42	-0.68	0.63	-0.02	0.15	0.35
BaseRate	-0.05	-0.36	0.5	1	-0.38	0.03	-0.4	0.78	-0.07	0.42	-0.25
M2	0.01	0.23	-0.65	-0.38	1	-0.25	0.97	-0.6	-0.01	-0.15	0.1
GDP G.R	0.17	0.22	0.42	0.03	-0.25	1	-0.27	0.2	0.18	-0.11	0.45
CPI	-0.02	0.2	-0.68	-0.4	0.97	-0.27	1	-0.64	0.03	-0.13	0.07
Long-term interest rate	-0.01	-0.21	0.63	0.78	-0.6	0.2	-0.64	1	0.01	0.24	-0.09
Foreign Net Buy	0.53	0.04	-0.02	-0.07	-0.01	0.18	0.03	0.01	1	-0.4	0.26
Institutional Net buy	-0.15	-0.38	0.15	0.42	-0.15	-0.11	-0.13	0.24	-0.4	1	-0.27
Sentiment	0.42	0.48	0.35	-0.25	0.1	0.45	0.07	-0.09	0.26	-0.27	1

4. 연구결과 및 해석

본 연구는 Phillips, Shi, and Yu(2015)의 PSY 절차와 머신러닝 분류모형을 결합하여, 한국 코스피(KOSPI) 시장에서의 주가 버블 탐지 및 예측 가능성을 실증적으로 분석하였다. 2005년 1월부터 2025년 12월까지 252개월의 월별 자료를 대상으로 GSADF 검정을 통해 버블 구간을 식별하고, 거시경제·금융 변수 및 뉴스 기반 감성 지표를 입력으로 한 XGBoost 분류모형의 예측 성능을 기준모형과 비교하였다.

4.1 주요 분석 결과

첫째, PSY 절차를 통한 버블 탐지 결과, GSADF 통계량(2.93)이 5% 유의수준 임계값(2.63)을 초과하여, 분석 기간 중 코스피 시장에 통계적으로 유의한 폭발적 가격 경로가 존재함을 확인하였다. 데이트스탬핑 결과 총 10개의 버블 에피소드가 식별되었으며, 전체 표본 중 48개월(19.0%)이 버블 구간으로 분류되었다. 식별된 에피소드는 2008년 글로벌 금융위기 전후, 2017~2018년 상승장, 2020~2021년 팬데믹 유동성 확대기 등 역사적으로 시장 과열이 지적되었던 시기와 대체로 일치하였다. 이는 PSY 검정이 한국 주식시장에서도 유효한 버블 탐지 도구로 기능할 수 있음을 시사한다.

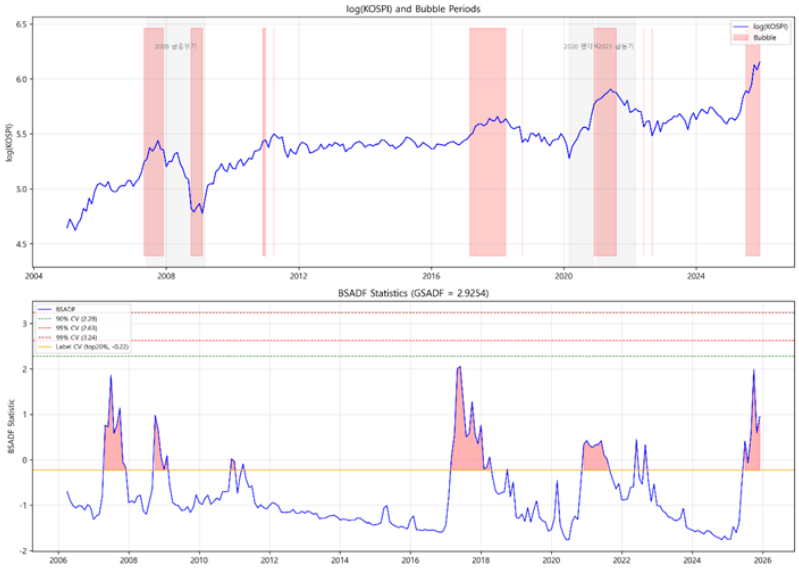

그림 1 BSADF 시계열 및 버블 구간 식별 결과

표 4 버블 에피소드 목록

Episode	Start	End	Duration (months)	Historical Context
1	May-07	Dec-07	8	2008 금융위기
2	Oct-08	Feb-09	5	2008 금융위기
3	Dec-10	Jan-11	2	
4	Apr-11	Apr-11	1	
5	Mar-17	Apr-18	14	
6	Oct-18	Oct-18	1	
7	Dec-20	Aug-21	9	2020 팬데믹
8	Jun-22	Jun-22	1	
9	Sep-22	Sep-22	1	
10	Jul-25	Dec-25	6	

둘째, 버블 구간과 비버블 구간의 변수 비교 분석에서 PER(t=2.08, p=0.042), PBR(t=2.63, p=0.011), 외국인 순매수(t=-2.09, p=0.041), 뉴스심리지수(t=2.14, p=0.037)가 통계적으로 유의한 차이를 보였다. 특히 버블 구간에서 PER과 PBR이 유의하게 높았다는 결과는 밸류에이션 과열이 버블과 동반됨을 확인해 주며, 외국인 순매수가 버블 구간에서 유의하게 감소한 것은 외국인 투자자가 시장 과열 국면에서 오히려 순매도 포지션을 취하는 경향이 있음을 시사한다. 뉴스심리지수가 버블 구간에서 유의하게 높았다는 결과는 투자자 심리가 한국 시장의 버블 형성과 유의미한 관련성을 가짐을 보여주며, 이는 기존 해외 연구에서 감성 지표의 효과가 제한적이었던 것과 구별되는 결과이다.

표 5 버블 라벨 기초통계 요약

Metric	Value
Total observations	252
Bubble months	48 (19.0%)
Non-bubble months	204 (81.0%)
bubble_up months	32 (66.7% of bubble)
bubble_down months	16 (33.3% of bubble)
Number of episodes	10
Average duration (months)	4.8
Maximum duration (months)	14
Class imbalance ratio	4.2:1

표 6 버블/비버블 변수 평균 비교(t-test)

Feature	Bubble Mean	Non-Bubble Mean	Difference	t-statistic	p-value
Return	0.9128	0.7294	0.1833	0.1675	0.8676
PER	16.39	14.4757	1.9143	2.0795	0.0421
PBR	1.2498	1.1404	0.1094	2.6312	0.0108
BaseRate	2.2344	2.5711	-0.3367	-1.4838	0.1431
M2	2403049	2183115	219933.8	1.3815	0.1716
GDP G.R	0.7	0.7868	-0.0868	-0.4567	0.6497
CPI	96.0758	94.3785	1.6973	0.879	0.3824

Long-term interest rate	3.3931	3.455	-0.0619	-0.2788	0.7812
Foreign Net Buy	-1205.95	88.7663	-1294.71	-2.0857	0.0413
Institutional Net buy	-159.292	66.5489	-225.841	-0.3873	0.7
news_sentiment	103.7896	99.1085	4.6811	2.1385	0.037

셋째, 머신러닝 예측 모형의 out-of-sample 성과에 있어 XGBoost 모형은 PR-AUC 0.46, F1 0.41, Balanced Accuracy 0.59, F1-macro 0.34를 기록하여, 단순 기준모형(PR-AUC 0.22, F1 0.00)을 모든 지표에서 상회하였다. 이에 따라 연구가설 H1, 즉 "PSY 절차로 정의된 코스피 버블 라벨은 거시·금융 변수를 입력으로 하는 XGBoost 분류모형을 통해 기준모형 대비 유의미하게 예측 가능하다"는 주장이 부분적으로 지지된다. 로지스틱 회귀 역시 PR-AUC 0.56, F1 0.40으로 기준모형을 상회하였으나, F1-macro 기준으로 XGBoost(0.34)가 로지스틱 회귀(0.29)를 상회하여 H1을 지지한다. 단, PR-AUC 기준으로는 로지스틱 회귀가 XGboost를 상회 하였다. F1-macro 기준으로는 XGboost가 가장 높아, 다중 라벨 분류에서의 균형 잡힌 예측력에서는 우위가 보였다.

메모 포함[상박15]: 좀 더 보수적으로 서술하기 위해 추가

표 7 모형별 OOS 예측 성과 비교

Model	bubble PR-AUC	bubble F1	Balanced Acc	F1-macro
XGBoost (Tuned)	0.4594	0.4103	0.5892	0.3388
Logistic Regression	0.5609	0.4048	0.5763	0.2932
Dummy (Always 0)	0.2237	0	0.5	0

표 8 학습-평가 구간 성과 격차

Model	Metric	Train	Test	Gap
XGBoost (Tuned)	PR-AUC	1	0.4594	0.5406
XGBoost (Tuned)	F1	1	0.4103	0.5897
XGBoost (Tuned)	Balanced Acc	1	0.5892	0.4108
Logistic Regression	PR-AUC	0.6635	0.5609	0.1025
Logistic Regression	F1	0.4651	0.4048	0.0604
Logistic Regression	Balanced Acc	0.6544	0.5763	0.0781
Dummy (Always 0)	PR-AUC	0.1761	0.2237	-0.0475
Dummy (Always 0)	F1	0	0	0
Dummy (Always 0)	Balanced Acc	0.5	0.5	0

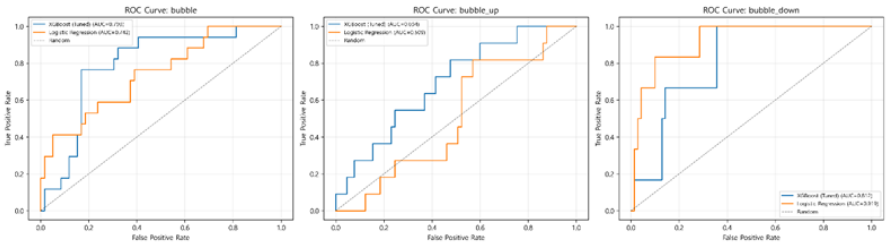

그림 2 ROC 곡선 비교

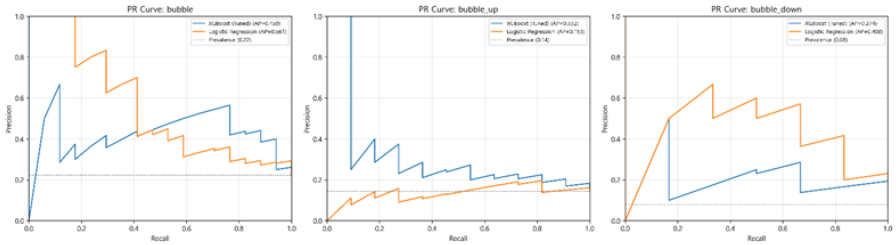

그림 3 PR 곡선 비교

넷째, 변수 중요도 분석 결과 XGBoost의 Gain 기준으로 PBR(0.22), M2(0.17), PER(0.15)가 상위 3개 변수로 나타나, 밸류에이션 지표와 유동성 변수가 버블 예측에 핵심적인 역할을 하는 것으로 확인되었다.

표 9 XGboost 변수 중요도

Feature	Gain Importance	Permutation Mean	Permutation Std
PBR	0.2176	-0.0061	0.0074
M2	0.1682	0	0
PER	0.1515	0.0544	0.049
GDP G.R	0.0788	0.0158	0.011
news_sentiment	0.078	0.0026	0.0104
CPI	0.074	0	0
Institutional Net buy	0.0604	0.0053	0.0064
BaseRate	0.0599	0.007	0.0066
Long-term interest rate	0.0565	0.007	0.0074
Return	0.0278	0	0
Foreign Net Buy	0.0275	0.0088	0.0119

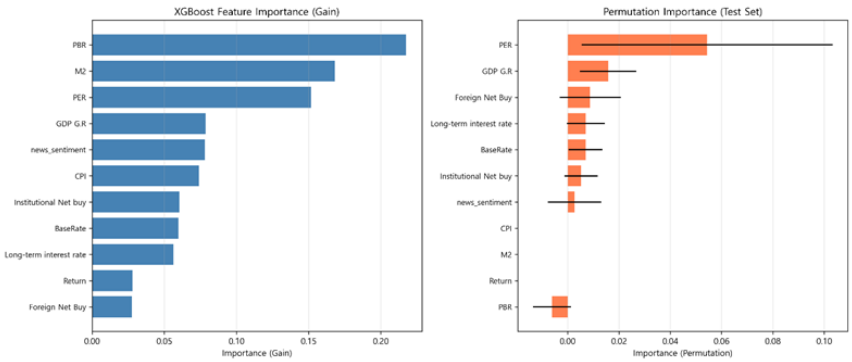

그림 4 변수 중요도 시각화

4.2 강건성 검증

4.2.1 최소 윈도우 길이 민감도 검증

r_0=12개월 및 15개월에서 GSADF 통계량이 95% 임계값을 근소하게 초과하였으나, r_0=18개월 및 24개월에서는 유의하지 않았다. 이는 버블 탐지 결과가 최소 윈도우 설정에 민감할 수 있음을 보여주며, PSY 절차 적용 시 파라미터 선택에 대한 신중한 고려가 필요함을 시사한다. ~~한편, 대안 모형으로 Random Forest를 적용한 결과 PR-AUC 0.58, F1 0.52, Balanced Accuracy 0.68을 기록하여 XGBoost 및 로지스틱 회귀를 상회하는 성능을 보였다. 이는 트리 기반 앙상블 모형이 버블 분류 문제에 전반적으로 적합하며, 모형 선택에 따른 추가적 성능 개선의 여지가 존재함을 의미한다.~~

메모 포함[상박16]: Random Forest 적용이 계속 걸린다고 지피티가 그래서 그냥 제외하고 트리 기반 모형을 추가로 적용해보는 것도 좋은 방법 중에 하나라고 언급

4.2.2 PSY 검정 변수의 선택과 P/D ratio의 한계

본 연구 이전, 코스피 시장의 배당수익률(Dividend Yield) 자료로부터 P/D ratio를 산출하여 PSY 검정을 수행한 결과, 버블이 검출되지 않았다(GSADF = 1.41, CV_{95} = 2.28). 이는 다음과 같은 원인에 기인한다.

첫째, 코스피 시장의 배당수익률은 분석 기간(20052025) 동안 1.022.73%의 좁은 범위 내에서 변동하였으며, 이를 역수로 변환한 P/D ratio(36.698.0)에 로그 변환을 적용하면 그 범위가 3.604.59로 전체 변동폭이 0.98에 불과하였다. PSY 검정의 임계값은 동일한 길이의 랜덤워크 시뮬레이션으로부터 산출되는데, T=252인 랜덤워크의 누적합은 전형적으로 15~20 수준의 변동폭을 보인다. 즉, 검정 변수의 신호(signal)에 비해 임계값이 구조적으로 높게 형성되어, 폭발적 행태가 존재하더라도 통계적으로 유의한 수준에 도달하기 어려운 스케일 불일치 문제가 발생하였다.

둘째, 한국 주식시장의 배당수익률은 미국 시장에 비해 구조적으로 낮고 안정적인 특성을 보인다. S&P 500의 경우 배당수익률이 역사적으로 1%대에서 6%대까지 넓은 범위에서 변동하여 P/D ratio의 변동성이 상대적으로 크지만, 코스피는 기업의 배당 성향이 상대적으로 낮고 일정하여 P/D ratio가 시장 과열 국면에서

도 뚜렷한 상승 가속을 나타내지 않는다.

셋째, 배당수익률은 기업의 배당 정책 변화, 지수 구성 종목 변경, 그리고 특별배당 등 가격 경로와 무관한 요인에 의해서도 변동한다. 이로 인해 P/D ratio에는 버블과 무관한 잡음(noise)이 포함되어, 가격 시계열 자체의 폭발적 특성을 희석시키는 효과가 있다.

이러한 한계를 고려하여, 본 연구에서는 P/D ratio 대신 코스피 지수의 로그 가격 log(KOSPI)을 PSY 검정 변수로 채택하였다.

5. 결론

5.1 학술적 · 실무적 시사점

본 연구의 학술적 기여는 다음과 같다.

첫째, 미국 S&P 500 중심으로 수행되어 온 PSY 기반 버블 탐지 및 머신러닝 예측 프레임워크를 한국 코스피 시장에 확장 적용한 실증 연구로서의 의의를 지닌다.

둘째, 뉴스 기반 감성 지표가 한국 시장에서 버블 구간과 유의미한 관련성을 보인다는 결과를 제시함으로써, 투자자 심리 변수의 역할에 대한 시장 간 비교 연구의 기초 자료를 제공하였다.

셋째, 버블 구간에서 외국인 투자자가 순매도 경향을 보인다는 발견은 한국 시장의 투자자 구조와 버블 형성 간의 관계에 대한 추가 연구의 필요성을 제기한다.

실무적 관점에서, 본 연구의 프레임워크는 금융감독 당국의 시장 과열 모니터링이나 보험 · 자산운용사의 리스크 관리 체계에 보조적인 조기경보 도구로 활용될 가능성을 제시한다. 특히 거시경제 및 밸류에이션 변수의 실시간 업데이트가 가능한 점을 고려하면, 정기적인 버블 발생 확률 산출 시스템으로의 확장이 가능하다.

5.2 한계 및 향후 연구

첫째, PSY 검정의 데이트스탬핑 결과가 최소 윈도우 길이 설정에 민감하며, 개별 시점의 BSADF 통계량에 대해서는 GSADF와 동일한 95% 임계값을 적용할 경우 버블로 식별되는 시점이 과도하게 적어지는 문제가 나타났다. 이에 본 연구에서는 데이트스탬핑 단계에서 90% 임계값을 적용하는 2단계 전략을 채택하였다; GSADF 통계량이 95% 임계값을 초과하여 전체 기간에 폭발적 행태가 존재함을 먼저 확인하고, 개별 시점의 버블 여부 판별에는 90% 임계값을 적용하여 데이트스탬핑을 수행. 이는 월별 빈도의 한국 주식시장 자료에서 PSY 절차의 검정력이 제한적일 수 있음을 시사하며, 일별 고빈도 자료 활용 시 개선될 여지가 있다.

메모 포함[상박17]: 앞문장에서 완화된 기준을 완화했다고 적었었는데 어떻게 완화한건지, 먼저 돌려보고 완화한건지 아니면 원래부터 완화된 기준을 적용한건지가 잘 드러나지 않아서 추가

둘째, XGBoost 모형의 학습 구간 성능과 평가 구간 성능 간 격차(PR-AUC Gap: 0.54)가 존재하여 과적합 가능성이 관찰되었으며, 정규화 강화 또는 앙상블 기법의 추가적 개선이 필요하다.

셋째, 설명변수를 시점 t 기준으로 구성하여 동시적 식별 문제를 다루었으나, t+1 시점 예측 구조로의 확장을 통해 실질적 사전 예측 가능성을 검증할 필요가 있다.

넷째, 기존 연구(Atsiwo, 2025)에서 XGboost의 성능지표가 다른 모델과 비교하여 우수함이 확인된 것과는 다소 상이하게, 본 연구의 결과는 버블 예측에 있어 XGboost 뿐만 아니라 다른 모델도 고려사항임을 시사한다. 이는 데이터의 차이 뿐 아니라 동일한 트리 기반 앙상블 내에서도 Random Forest와 같은 Bagging 계열이나 LightGBM과 같은 다른 Boosting 변형 적용을 통해 모형 간 성능 비교를 확장할 수 있음을 의미한다.

향후 연구에서는 일별 자료를 활용한 PSY 검정력 개선, LSTM 등 시계열 딥러닝 모형의 적용, 그리고 다국가 비교 분석을 통해 본 연구의 프레임워크를 보다 일반화할 수 있을 것으로 기대한다.

References

1. Alessi, L., & Detken, C. (2011). Quasi real-time early warning indicators for costly asset price boom/bust cycles. European Journal of Political Economy, 27(3), 520-533.
2. Atsiwo, A. (2025). A three-step machine learning approach to predict market bubbles with financial news (Preprint). arXiv. https://doi.org/10.48550/arXiv.2510.16636
3. Baker, M., & Wurgler, J. (2006). Investor sentiment and the cross-section of stock returns. Journal of Finance, 61(4), 1645-1680.
4. Başgölu Kabran, F., & Ünlü, K. D. (2021). A two-step machine learning approach to predict S&P 500 bubbles. Journal of Applied Statistics, 48(13-15), 2776-2794. https://doi.org/10.1080/02664763.2020.1823947
5. Bernanke, B. S., & Gertler, M. (2001). Should central banks respond to asset prices? American Economic Review, 91(2), 253-257.

6. Blanchard, O. J., & Watson, M. W. (1982). Bubbles, rational expectations and financial markets. In P. Wachtel (Ed.), Crises in the economic and financial structure (pp. 295-315). Lexington Books.

7. Chatzis, S. P., Siakoulis, V., Petropoulos, A., Stavroulakis, E., & Vlachogiannakis, N. (2018). Forecasting stock market crisis events using deep and statistical machine learning techniques. Expert Systems with Applications, 112, 353-371.

8. Diba, B. T., & Grossman, H. I. (1988). The theory of rational bubbles in stock prices. Economic Journal, 98(392), 746-754.

9. Dickey, D. A., & Fuller, W. A. (1979). Distribution of the estimators for autoregressive time series with a unit root. Journal of the American Statistical Association, 74(366), 427-431.

10. Kim, S., & Park, H. (2021). GSADF를 이용한 서울주택시장의 다중거품에 대한 연구. 주거환경, 19(1), 39-55.

11. Ozgur, O., Yilanci, V., & Ozbugday, F. C. (2021). Detecting speculative bubbles in metal prices. Resources Policy, 74, 102276. https://doi.org/10.1016/j.resourpol.2021.102276

12. Phillips, P. C. B., & Shi, S. (2020). Real-time monitoring of asset markets. Handbook of Statistics, 42, 61-80.

13. Phillips, P. C. B., Shi, S., & Yu, J. (2015a). Testing for multiple bubbles: Historical episodes of exuberance and collapse in the S&P 500. International Economic Review, 56(4), 1043-1078.

14. Phillips, P. C. B., Shi, S., & Yu, J. (2015b). Limit theory for moderate deviations from a unit root. Econometric Theory, 31(2), 346-369.

15. Phillips, P. C. B., Wu, Y., & Yu, J. (2011). Explosive behavior in the 1990s Nasdaq: When did exuberance escalate asset values? International Economic Review, 52(1), 201-226.

16. Jeon, H. (2023). 오피스 시장 버블에 관한 연구: RADF 검정과 GSADF 검정을 이용하여. 한국콘텐츠학회 논문지, 23(4), 314-320.

17. Sarlin, P. (2013). On policymakers' loss functions and the evaluation of early warning systems. Economics Letters, 119(1), 1-7.

18. Shiller, R. J. (2000). Irrational exuberance. Princeton University Press.

19. Shu, M., & Song, R. (2024). Detection of financial bubbles using a log-periodic power law singularity (LPPLS) model. Wiley Interdisciplinary

Reviews: Computational Statistics, 16(2), e1649. https://doi.org/10.1002/wics.1649

20. Yang, H., & Lee, J. (2024). Detection of stock price bubbles in KOSPI and KOSDAQ industries and selection of predictive covariates using penalized logit models. 시장경제연구, 53(2), 1-38. https://doi.org/10.38162/JOME.53.2.1

21. West, K. D. (1987). A specification test for speculative bubbles. Quarterly Journal of Economics, 102(3), 553-580.

댓글로 남기지 않은 수정 사항

인용 형식 통일함

자잘자잘한 수정(문단 바꾸기, 오타 등)